

PROJETO INTEGRADOR — DA INGESTÃO À DECISÃO

1. Objetivo

Construir, do zero, um pipeline de dados completo que parte de bases públicas reais, atravessa as camadas Bronze, Silver e Gold, e termina em uma recomendação de decisão sustentada por um modelo preditivo honesto. O projeto integra os três blocos vistos em sala: ingestão de dados, boas práticas de pipeline e fundamentos ML-Ready.

O grupo não recebe o problema pronto. Vocês escolhem as bases, descobrem o que o cruzamento delas permite responder e decidem qual decisão o projeto vai apoiar. Essa escolha é parte da avaliação: um pipeline tecnicamente impecável que não serve para decidir nada vale menos do que um pipeline simples que muda a ação de alguém.

2. A pergunta que o projeto precisa responder

Ao final, o grupo deve conseguir completar esta frase com números do próprio pipeline:

"Cruzando as bases X, Y e Z, identificamos que _____. Recomendamos que _____ faça _____ nos próximos _____, priorizando _____. Se agir, o ganho esperado é _____; se errarmos, o custo é _____."

Repare no que a frase exige: um responsável concreto pela decisão, uma ação possível, um prazo e o custo de errar. Um número que não muda a ação de ninguém não é resultado — é curiosidade.

3. Requisito 1 — Escolha e cruzamento das bases

- Mínimo de duas ou mais bases públicas reais, de pelo menos duas instituições diferentes. Dados sintéticos, de exemplo ou de tutorial não são aceitos.
- Pelo menos dois formatos distintos entre as fontes (CSV, JSON, XLSX, Parquet, banco relacional, API REST).
- Pelo menos uma fonte acessada por API e uma por arquivo.
- **Uma chave de cruzamento explícita e documentada:** código IBGE de município, UF, ano/mês, código INEP de escola, CNPJ, CID-10 ou equivalente. O grupo deve relatar quantos registros casaram e quantos ficaram órfãos no join — e o que fez com os órfãos.
- Fontes com licença de uso aberto, com URL e data de coleta registradas no dicionário de dados.

Antes de fechar o tema, baixe uma amostra real de cada base. Muito projeto morre no segundo encontro porque a base "que existia" está atrás de um login, tem 40 GB ou parou de ser atualizada em 2019.

3.1. Catálogo de fontes sugeridas

Endereços conferidos em 26/08/2026. Portais públicos mudam de estrutura com frequência: se um link falhar, procure o conjunto pelo nome em dados.gov.br antes de trocar de fonte.

Fonte e endereço	O que oferece	Acesso	Chave típica
IBGE — SIDRA e API de Agregados https://apisidra.ibge.gov.br https://servicodados.ibge.gov.br/api/docs	População, PIB municipal, produção agrícola e demais tabelas do SIDRA	API REST (JSON)	código IBGE do município, ano
Base dos Dados https://basedosdados.org	Centenas de bases brasileiras já tratadas e padronizadas, inclusive RAIS e Censo	CSV, SQL no BigQuery, pacotes Python e R	id_municipio, ano
INEP — Microdados https://www.gov.br/inep/pt-br/aceso-a-informacao/dados-abertos/microdados	Censo Escolar, Censo da Educação Superior, ENEM, indicadores educacionais	ZIP com CSV separado por pipe ()	código INEP da escola, município
OpenDataSUS https://opendatasus.saude.gov.br	Mortalidade (SIM), notificações (SINAN), SRAG, vacinação e outras bases do SUS	CSV e API (CKAN)	município, CID, competência
INPE — Programa Queimadas https://data.inpe.br/queimadas/dados-abertos/	Focos de calor, de séries anuais até atualização a cada 10 minutos	CSV e KML	município, data
INMET — BDMEP https://bdmep.inmet.gov.br https://portal.inmet.gov.br/dadoshistoricos	Séries históricas de chuva, temperatura, umidade e vento por estação	CSV (ZIP anual ou por estação)	código da estação, data
Portal da Transparência https://portaldatransparencia.gov.br/download-de-dados https://portaldatransparencia.gov.br/api-de-dados	Contratos, convênios, licitações, despesas, benefícios sociais e servidores	CSV e API REST (exige cadastro; há limite por minuto)	CNPJ, município, ano
Banco Central — SGS https://dadosabertos.bcb.gov.br https://api.bcb.gov.br/dados/serie/bcdata.sgs.11/dados?formato=json	Séries econômicas: câmbio, Selic, crédito, inadimplência, IBC-Br	API REST JSON (máx. 10 anos por consulta)	data
PDET — RAIS e Novo CAGED https://www.gov.br/trabalho-e-emprego/pt-br/assuntos/estatisticas-trabalho/microdados-rais-e-caged	Admissões e desligamentos por município, setor e ocupação	TXT com separador ';', baixado por FTP	município, competência, CNAE
ANP — Dados abertos https://www.gov.br/anp/pt-br/centrais-de-conteudo/dados-abertos	Série histórica semanal de preços de combustíveis e GLP por revendedor	CSV	município, semana, CNPJ do posto
ANEEL — Dados abertos https://dadosabertos.aneel.gov.br	Geração distribuída, tarifas, interrupções e indicadores de distribuidoras	CSV e JSON (CKAN)	município, distribuidora, mês
Portal Brasileiro de Dados Abertos https://dados.gov.br/dados/conjuntos-dados	Catálogo geral do governo federal e caminho para portais estaduais e municipais	variado (CSV, JSON, API)	variado

3.2. Exemplos de cruzamento

- Internações respiratórias por município (DATASUS) × focos de calor (INPE) × chuva e umidade (INMET) — para priorizar municípios em campanha de saúde no período de estiagem.

- IDEB e Censo Escolar (INEP) × PIB e população (IBGE) × transferências ao município (Transparência) — para escolher onde aplicar um programa de reforço escolar.
- Admissões e desligamentos (CAGED) × matrículas em cursos técnicos (INEP) — para decidir a oferta de vagas do próximo ano.
- Produção agrícola municipal (SIDRA) × séries climáticas (INMET) × preços (ANP/CONAB) — para antecipar risco de quebra de safra.

Escolher um tema desta lista é permitido. Escolher um tema próprio, com dados do Pará ou de Belém.

4. Requisito 2 — Ingestão

O pipeline deve implementar, no mínimo, três formas distintas de ingestão entre as vistas em sala:

- arquivo (CSV, JSON aninhado ou Excel), com tratamento explícito de encoding, separador e tipagem;
- API REST, com paginação, tratamento de erro e retry com backoff — nada de baixar o JSON à mão e commitar;
- banco relacional, em full load ou incremental por watermark;
- carga incremental, CDC ou micro-batch com checkpoint, para pelo menos uma fonte que se atualize.

Além disso, obrigatoriamente:

- **Metadados técnicos** em todo registro da Bronze: horário de ingestão, sistema de origem, objeto de origem, identificador da carga e hash do registro.
- **Idempotência demonstrável**: rodar a ingestão duas vezes seguidas não pode duplicar dados na camada final. O grupo deve mostrar essa execução dupla na defesa.
- **Quarentena**: registros e arquivos problemáticos vão para área separada, com o motivo registrado. O job não pode quebrar por causa de dado sujo — e nada pode sumir sem rastro.

5. Requisito 3 — Arquitetura medalhão

Camada	O que precisa estar lá	O que não pode estar
Bronze	Dado como veio da fonte, imutável, com metadados técnicos e particionamento por data	Regra de negócio, deduplicação semântica, agregação, descarte de registro
Silver	Tipagem forte, padronização, chave e granularidade declaradas, deduplicação, validações com quarentena, integridade referencial do join	Dado sem contrato definido; correção silenciosa que ninguém consegue explicar
Gold	Tabelas orientadas à pergunta de decisão: agregações, indicadores e a base ML-Ready	Qualquer limpeza — se precisou limpar aqui, a Silver falhou

Cada tabela precisa ter granularidade declarada em uma frase ("uma linha por município por mês") e chave primária verificada — o grupo deve provar, com código, que não há duplicata na chave.

6. Requisito 4 — Repositório e reprodutibilidade

- Repositório Git com estrutura separando código-fonte, notebooks, scripts e documentação.
- `requirements.txt` com versões fixadas, e README que permita a outra pessoa executar o pipeline inteiro do zero seguindo apenas o que está escrito.
- **Dados não vão para o Git.** A pasta de dados entra no `.gitignore`; o repositório guarda código e metadados. Se a base é pequena e a licença permite, guarde o script que a baixa, não o arquivo.
- Seeds fixas em toda operação aleatória (amostragem, split, inicialização do modelo).
- Dicionário de dados: para cada tabela da Silver e da Gold — coluna, tipo, domínio de valores válidos, origem e significado de negócio.
- Histórico de commits distribuído entre os integrantes. Um repositório com 3 commits no último dia, todos do mesmo autor, será tratado como trabalho de uma pessoa só.

7. Requisito 5 — Base ML-Ready e anti-vazamento (Opcional)

Este é o requisito com maior peso na avaliação. O grupo precisa documentar, antes de treinar qualquer modelo:

Elemento	O que documentar
Label	O que exatamente é o positivo, e em que momento se sabe que o evento ocorreu
Regra de rotulagem	A condição formal do evento, objetiva e reproduzível em código
Coorte	Quem é elegível no t_0 — e quais casos impossíveis foram excluídos, com justificativa
Ponto de corte (t_0)	O instante em que o conhecimento do modelo é congelado
Janela de observação	O período de onde vêm as features, sempre anterior ao t_0
Janela de predição	O período em que o label é observado, sempre posterior ao t_0
Split	Temporal, por grupo, ou os dois — com a justificativa da escolha
Baseline	O modelo trivial contra o qual o seu será comparado (média, moda, regra simples)
Métrica	A métrica escolhida e por que ela é adequada ao desbalanceamento do problema

O relatório deve incluir o checklist anti-vazamento respondido item a item:

- Toda feature existia antes do t_0 ?
- As agregações foram calculadas apenas com dados anteriores ao t_0 de cada observação?
- O split respeita tempo e grupo? Nenhuma entidade aparece em treino e teste ao mesmo tempo?
- Scalers, encoders e imputadores foram ajustados (`fit`) somente no treino?

Métrica alta demais é motivo de investigação, não de comemoração. Se o modelo do grupo acertar quase tudo, esperem ser perguntados por qual coluna vazou o futuro — e a resposta "não vazou nada" precisará de prova.

8. Requisito 6 — A decisão é escolha do grupo

Não existe entrega padrão. O grupo define o que produzir a partir do que os dados sustentam: uma lista priorizada de municípios, um alerta antecipado, uma recomendação de alocação de recursos, um painel de risco, um score de triagem. O que a banca vai cobrar é a coerência entre a pergunta, os dados e a ação proposta.

A entrega de decisão precisa deixar explícito:

- quem é o decisor (secretaria, gestor, coordenação, empresa) e que ação concreta ele pode tomar;
- qual o custo de um falso positivo e de um falso negativo naquele contexto — em recurso, tempo ou risco;
- qual o limiar adotado e por quê, ligando a métrica técnica à consequência prática;
- quais as limitações: o que os dados não permitem afirmar, e o que seria preciso para afirmar.
- explicar linha a linha.

9. Uso de IA, dados e integridade

Ferramentas de IA generativa podem ser usadas e devem ser declaradas no README: para quê foram usadas e em que partes. O critério é simples e será testado na arguição: todo integrante precisa saber explicar qualquer trecho do que foi entregue. Código que ninguém do grupo consegue justificar conta como não entregue.

Trabalhe apenas com dados abertos e agregados. Se a base contiver identificação pessoal, o tratamento (anonimização ou agregação) deve ocorrer já na passagem para a Silver e ser documentado. Cite a fonte, a data de coleta e a licença de cada base.